

Rapport de Stage : le Développement d'un Portail RH avec Intelligence Artificielle

Extraction Automatique de Données à partir de Documents Administratifs

Stagiaire : Hamza Elmourabit

Filière : Big Data et Systèmes d'Information

Encadrant entreprise : M. Mounir Chaïabi

Établissement d'accueil :

Office National de l'Électricité et de l'Eau

Potable Branche Électricité

Période : 1 juillet au 31 juillet 2025

31 juillet 2025

Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réussite de ce stage et à l'élaboration de ce rapport.

Je remercie chaleureusement M. Mounir Chaïabi, mon encadrant au sein de l'ONEE – Branche Électricité, pour sa confiance, ses conseils avisés et son accompagnement tout au long de ce projet. Sa disponibilité, son expertise technique et ses orientations précieuses ont été déterminantes pour la réussite de cette mission.

Je remercie également l'équipe du service informatique de l'ONEE pour leur accueil, leur collaboration et les échanges enrichissants qui ont facilité mon intégration et mon travail au sein de l'entreprise.

Ma reconnaissance va également à l'ENSA Berrechid et à l'ensemble du corps professoral pour la formation de qualité reçue et pour m'avoir donné l'opportunité de mettre en pratique mes connaissances dans un environnement professionnel stimulant.

Enfin, je remercie tous les stagiaires et collègues qui ont partagé cette expérience avec moi et qui ont contribué, par leurs conseils et leur soutien, à rendre ce stage plus enrichissant.

Table des matières

1	Introduction Générale	3
2	Contexte et Problématique	3
2.1	Environnement numérique à l'ONEE	3
2.2	Processus actuel de gestion des documents RH	4
2.3	Problématique identifiée	4
2.4	Opportunités d'amélioration	5
3	Objectifs du Stage	5
3.1	Objectif principal	5
3.2	Objectifs spécifiques	5
3.3	Périmètre du projet	6
4	Étude et Analyse des Besoins	6
4.1	Documents ciblés	6
4.2	Champs à extraire	6
4.3	Exigences fonctionnelles	6
4.4	Exigences non fonctionnelles	7
4.5	Analyse des solutions existantes	7
5	Conception de la Solution IA et Architecture du Portail RH	7
5.1	Architecture générale de la solution IA	7
5.2	Flux de traitement détaillé	7
5.3	Choix technologiques	9
5.4	Modélisation des données	9
5.4.1	Schéma JSON	9
5.5	Architecture globale du Portail RH.....	10

6	Implémentation Technique	10
6.1	Environnement de développement	10
6.2	Prétraitement des images	10
6.3	Reconnaissance optique de caractères (OCR).....	11
6.4	Extraction des données	11
6.4.1	Extraction des données de CIN	11
6.4.2	Extraction des données de CV	12
6.5	Stockage des données.....	13
6.6	Interface web	13
7	Fonctionnalités du Portail RH	15
7.1	Intelligence Artificielle Intégrée	15
7.2	Gestion des Employés	15
7.3	Recrutement Intelligent.....	16
7.4	Analytics et Reporting.....	16
8	Résultats Obtenus	17
8.1	Taux de réussite d'extraction	17
8.2	Analyse des erreurs.....	17
8.3	Performances du système.....	17
8.4	Gains opérationnels	17
9	Difficultés Rencontrées et Solutions Proposées	18
9.1	Qualité des documents sources.....	18
9.2	Reconnaissance des caractères arabes	18
9.3	Variabilité des formats de documents.....	19
9.4	Gestion des erreurs d'extraction.....	19
10	Perspectives d'Amélioration	20
10.1	Utilisation de modèles IA avancés.....	20
10.2	Industrialisation de la solution	21
11	Conclusion	22
11.1	Bilan du projet.....	22
11.2	Compétences développées	22
11.3	Apports à l'ONEE.....	22
11.4	Conclusion générale	22

1 Introduction Générale

Dans le cadre de l'évolution constante des technologies et de la transformation numérique, les entreprises cherchent continuellement à optimiser leurs processus internes afin d'accroître leur efficacité et leur compétitivité. Le domaine des Ressources Humaines (RH), traditionnellement caractérisé par des tâches administratives répétitives et une gestion intensive de documents, représente un terrain fertile pour l'application de solutions innovantes. L'intégration de l'Intelligence Artificielle (IA) dans les systèmes de gestion des RH (SIRH) est devenue une tendance majeure, promettant de révolutionner la manière dont les organisations gèrent leurs talents, de l'acquisition à la rétention.

Ce rapport détaille le développement d'un projet ambitieux visant à créer un portail RH moderne, enrichi par des fonctionnalités d'intelligence artificielle. L'objectif principal de ce projet est d'automatiser et d'optimiser des processus clés des RH, notamment l'extraction automatique de données à partir de documents administratifs tels que les Cartes d'Identité Nationales (CIN), les diplômes et les Curriculum Vitæ (CV). Cette automatisation vise à réduire la charge de travail manuelle, à minimiser les erreurs et à accélérer le traitement des informations, permettant ainsi aux professionnels des RH de se concentrer sur des tâches à plus forte valeur ajoutée.

Le projet a été mené au sein de l'Office National de l'Électricité et de l'Eau Potable (ONEE) – Branche Électricité, un établissement public marocain jouant un rôle crucial dans le secteur énergétique du pays. L'ONEE, en tant qu'acteur majeur, est engagé dans une démarche de modernisation de ses infrastructures et de ses processus, y compris ceux liés à la gestion de son capital humain. Le stage, d'une durée de quatre mois, a permis d'explorer et de mettre en œuvre des solutions basées sur l'IA pour répondre aux défis spécifiques rencontrés par le département RH de l'ONEE, notamment la gestion d'un volume important de documents papier et numériques.

Ce rapport est structuré pour présenter une vue d'ensemble complète du projet. Il débutera par une présentation du contexte du stage et de l'organisme d'accueil, l'ONEE, suivie d'une analyse approfondie de la problématique existante et des opportunités d'amélioration. Nous décrirons ensuite les objectifs spécifiques du stage, le périmètre du projet et les contraintes techniques rencontrées. Les phases d'étude et d'analyse des besoins, de conception de la solution IA, et d'implémentation technique seront détaillées, incluant les choix technologiques et l'architecture globale du système. Une section sera dédiée aux fonctionnalités avancées du portail RH intégrant l'IA, suivie d'une évaluation des résultats obtenus, des difficultés rencontrées et des solutions apportées. Enfin, nous aborderons les perspectives d'amélioration et les possibilités de déploiement futur, avant de conclure sur le bilan global du projet et ses apports significatifs pour l'ONEE.

2 Contexte et Problématique

2.1 Environnement numérique à l'ONEE

L'Office National de l'Électricité et de l'Eau Potable (ONEE) – Branche Électricité, en tant qu'acteur majeur du secteur énergétique marocain, est profondément engagé dans une démarche de modernisation et de digitalisation de ses opérations. Cette transformation numérique vise à optimiser l'efficacité, à améliorer la qualité des services et à renforcer la compétitivité de l'organisation. Dans ce contexte, l'environnement numérique de l'ONEE est caractérisé par une infrastructure informatique robuste, mais également par la coexistence de systèmes hérités et de processus manuels, notamment au sein de ses départements administratifs et de gestion des ressources humaines.

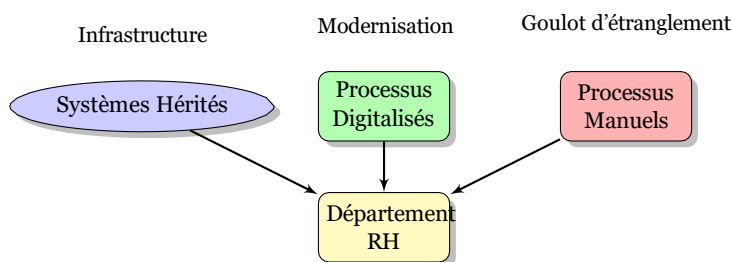


Figure 1 – Environnement numérique à l'ONEE

2.2 Processus actuel de gestion des documents RH

Actuellement, la gestion des documents au sein du département des Ressources Humaines de l'ONEE repose en grande partie sur des processus manuels et semi-automatisés. Un volume considérable de documents administratifs, tels que les Cartes d'Identité Nationales (CIN), les diplômes, les Curriculum Vitæ (CV), les attestations de travail, et autres pièces justificatives, est traité quotidiennement. Ces documents sont réceptionnés sous diverses formes (papier, scans, fichiers numériques), puis font l'objet d'une vérification, d'une saisie manuelle des informations pertinentes dans les systèmes d'information RH, et d'un archivage physique ou numérique.




Figure 2 – Processus actuel de gestion des documents RH

2.3 Problématique identifiée

La gestion manuelle des documents RH à l'ONEE engendre une série de problématiques significatives :

- **Chronophage et Coûteux** : La saisie manuelle des données est une tâche répétitive et fastidieuse qui consomme un temps considérable pour le personnel RH. Ce temps pourrait être alloué à des activités à plus forte valeur ajoutée, telles que le développement des compétences des employés, la gestion des carrières ou l'amélioration de l'expérience collaborateur. De plus, les coûts associés à la main-d'œuvre dédiée à ces tâches de saisie et d'archivage sont non négligeables.
- **Risque d'Erreurs Humaines** : La saisie manuelle est intrinsèquement sujette aux erreurs. Des fautes de frappe, des omissions ou des interprétations incorrectes des informations peuvent entraîner des inexactitudes dans les bases de données RH. Ces erreurs peuvent avoir des conséquences importantes, allant de la difficulté à retrouver des informations précises à des problèmes de conformité réglementaire, en passant par des décisions basées sur des données erronées.
- **Difficulté d'Accès et de Recherche** : L'archivage physique des documents rend leur accès et leur recherche complexes et lents. Même avec des systèmes d'archivage numérique basiques, l'absence d'une indexation automatique et structurée des informations rend la récupération des données fastidieuse. Cela nuit à la réactivité du département RH et à sa capacité à fournir rapidement les informations nécessaires aux autres services ou aux employés eux-mêmes.
- **Manque de Standardisation et d'Intégration** : La diversité des formats de documents et l'absence de processus d'extraction standardisés compliquent l'intégration des données dans les différents systèmes d'information de l'ONEE. Cela crée des silos d'information et limite la capacité de l'organisation à avoir une vue d'ensemble consolidée et à jour de ses ressources.

humaines.

- **Sécurité et Confidentialité des Données** : La manipulation manuelle et l'archivage physique des documents sensibles augmentent les risques de perte, de vol ou d'accès non autorisé aux informations confidentielles des employés. Dans un contexte où la protection des données personnelles est de plus en plus réglementée (par exemple, le RGPD ou ses équivalents locaux), ces pratiques posent des défis majeurs en termes de conformité et de sécurité.

2.4 Opportunités d'amélioration

Face à ces problématiques, l'intégration de solutions basées sur l'Intelligence Artificielle offre des opportunités significatives pour transformer la gestion des documents RH à l'ONEE :

- **Accélérer le Traitement** : Réduire drastiquement le temps nécessaire à la saisie et à l'intégration des informations, permettant un traitement quasi instantané des nouveaux documents.
- **Améliorer la Précision** : Minimiser les erreurs humaines grâce à des algorithmes d'extraction et de validation robustes, garantissant une meilleure qualité des données.
- **Optimiser les Ressources** : Libérer le personnel RH des tâches répétitives pour qu'il puisse se concentrer sur des initiatives stratégiques et des interactions humaines.
- **Faciliter l'Accès aux Données** : Structurer automatiquement les informations extraites dans des formats exploitables (comme JSON) et les intégrer directement dans les bases de données, rendant les données facilement interrogeables et analysables.
- **Renforcer la Sécurité** : Réduire la manipulation physique des documents et centraliser les données dans des systèmes sécurisés, améliorant ainsi la conformité et la protection des informations sensibles.

3 Objectifs du Stage

3.1 Objectif principal

L'objectif principal de ce stage était de développer un module d'intelligence artificielle capable d'extraire automatiquement des données clés à partir de documents administratifs non structurés ou semi-structurés, tels que les Cartes d'Identité Nationales (CIN), les diplômes et les Curriculum Vitæ (CV). Ce module devait s'intégrer dans un système plus large de gestion des ressources humaines, contribuant ainsi à l'automatisation et à l'optimisation des processus RH au sein de l'ONEE.

3.2 Objectifs spécifiques

Pour atteindre cet objectif principal, plusieurs objectifs spécifiques ont été définis :

- **Analyse et Maîtrise des Technologies OCR** : Étudier et comprendre les différentes technologies de Reconnaissance Optique de Caractères (OCR) disponibles, évaluer leur performance et leur adaptabilité aux documents spécifiques de l'ONEE, et sélectionner les outils les plus appropriés pour l'extraction de texte.
- **Extraction Automatique des Champs Clés** : Mettre en œuvre des algorithmes et des techniques permettant d'identifier et d'extraire avec précision les informations pertinentes (nom, prénom, numéro CIN, date de naissance, établissement, type de diplôme, compétences, expériences professionnelles, etc.) à partir des documents traités.
- **Structuration des Données Extraites** : Transformer les données brutes extraites en un format structuré et standardisé, tel que JSON, afin de faciliter leur manipulation, leur stockage et leur intégration dans d'autres systèmes d'information.
- **Intégration dans une Base de Données** : Assurer le stockage persistant des données extraites dans des bases de données adaptées (MongoDB pour les données non structurées ou semi-

structurées, et MySQL pour les données relationnelles), garantissant ainsi leur accessibilité et leur intégrité.

- **Développement d’une Interface Utilisateur Intuitive** : Concevoir et implémenter une interface web conviviale permettant aux utilisateurs RH de téléverser les documents, de visualiser les données extraites, de valider ou de corriger manuellement les informations si nécessaire, et de gérer l’historique des traitements.

3.3 Périmètre du projet

Le périmètre du projet a été délimité pour se concentrer sur les aspects les plus critiques et les plus impactants pour l’ONEE :

Élément	Description
Types de documents	CIN, diplômes universitaires, CV
Langues prises en charge	Français, Arabe
Champs extraits	Informations personnelles, coordonnées, qualifications, expériences professionnelles, compétences
Technologies utilisées	Python, OpenCV, Tesseract, MongoDB, MySQL, Streamlit
Contraintes techniques	Qualité variable des documents, variabilité des formats, reconnaissance arabe complexe

Table 1 – Périmètre du projet

4 Étude et Analyse des Besoins

4.1 Documents ciblés

L’étude des besoins a permis d’identifier trois types de documents principaux à traiter par le module d’IA :

- **Carte d’Identité Nationale (CIN)** : Document fondamental pour l’identification des individus. Structure relativement standardisée facilitant l’extraction. Contient informations personnelles, photo, signature.
- **Diplômes universitaires** : Attestent des qualifications académiques. Variabilité des formats selon les établissements et les époques. Contiennent informations sur le diplômé, l’établissement, la spécialité.
- **Curriculum Vitæ (CV)** : Document le plus complexe en raison de sa structure hautement variable et non standardisée. Contient coordonnées, formation, expérience, compétences.

4.2 Champs à extraire

Sur la base de l’analyse des documents cibles, les champs suivants ont été identifiés pour l’extraction automatique :

4.3 Exigences fonctionnelles

Les exigences fonctionnelles décrivent ce que le système doit faire pour satisfaire les besoins des utilisateurs :

- **Téléversement de documents** : Le système doit permettre aux utilisateurs de téléverser des documents sous différents formats (PDF, JPEG, PNG) via une interface web.

Type de document	Champs à extraire
CIN	Nom, prénom, date de naissance, lieu de naissance, numéro CIN, adresse
Diplôme	Nom, prénom, diplôme, établissement, date d'obtention, spécialité, mention
CV	Nom, prénom, adresse, téléphone, email, formation, expérience professionnelle, compétences, langues

Table 2 – Champs à extraire par type de document

- **Extraction automatique de données** : Le module IA doit être capable d'extraire automatiquement les champs définis à partir des documents téléversés.
- **Prise en charge multilingue** : Le système doit pouvoir traiter des documents rédigés en français et en arabe.
- **Structuration des données** : Les données extraites doivent être formatées en JSON pour une intégration facile dans la base de données.
- **Visualisation des données extraites** : L'interface utilisateur doit afficher clairement les données extraites pour permettre une vérification rapide.
- **Validation et correction manuelle** : Les utilisateurs doivent pouvoir valider les données extraites et corriger manuellement les erreurs ou les omissions via l'interface.
- **Stockage des données** : Les données validées doivent être stockées de manière persistante dans une base de données (MongoDB et MySQL).
- **Historique des traitements** : Le système doit conserver un historique des documents traités et des extractions effectuées.

4.4 Exigences non fonctionnelles

Les exigences non fonctionnelles spécifient les critères de performance, de sécurité et de qualité du système :

4.5 Analyse des solutions existantes

Une analyse comparative des solutions existantes a été menée pour éclairer les choix technologiques :

5 Conception de la Solution IA et Architecture du Portail RH

5.1 Architecture générale de la solution IA

La solution d'extraction de données par IA est conçue comme un pipeline modulaire, où chaque étape est spécialisée dans une tâche spécifique, garantissant ainsi une meilleure maintenabilité et une plus grande flexibilité. Ce pipeline est activé lorsqu'un utilisateur téléverse un document (CIN, diplôme, CV) via l'interface du portail RH.

5.2 Flux de traitement détaillé

Le flux de traitement des documents a été conçu pour être linéaire et efficace :

1. **Téléversement du Document** : L'utilisateur soumet un document (PDF ou image) via l'interface web.

Exigence	Description
Précision	Taux de réussite > 85% pour CIN/-diplômes, > 70% pour CV
Performance	Temps de traitement < 10 secondes par document
Scalabilité	Capacité à gérer un volume croissant de documents sans dégradation significative des performances
Sécurité	Protection des données sensibles contre les accès non autorisés, la perte ou la corruption
Fiabilité	Fonctionnement stable et continu, avec un minimum d'interruptions
Utilisabilité	Interface intuitive, facile à apprendre et agréable à utiliser pour les professionnels RH
Maintenabilité	Code source bien structuré, documenté et facile à maintenir et à faire évoluer

Table 3 – Exigences non fonctionnelles

Technologie	Avantages	Inconvénients
Tesseract OCR	Open source, support multi-lingue, bonne précision	Configuration complexe, perform
Google Cloud Vision	Très précise, support multi-lingue avancé	Coût par utilisation, nécessite co
OpenCV	Très complète, nombreuses fonctionnalités	Courbe d'apprentissage steep
MongoDB	Schéma flexible, bonne pour données non structurées	Moins adapté pour transactions
MySQL	Bonnes performances pour requêtes complexes	Moins flexible pour données évol
Streamlit	Très rapide à développer	Personnalisation limitée

Table 4 – Comparaison des solutions existantes

2. **Prétraitement des Images** : Le document est d'abord traité pour améliorer sa qualité et optimiser la reconnaissance optique de caractères. Cette étape inclut :
 - Conversion des PDF en images
 - Redressement des images inclinées
 - Binarisation (conversion en noir et blanc)
 - Amélioration de la netteté et suppression du bruit
3. **Reconnaissance Optique de Caractères (OCR)** : Une fois l'image prétraitée, le moteur OCR est appliqué pour convertir le texte de l'image en texte numérique.
4. **Extraction des Champs** : Le texte brut obtenu par l'OCR est ensuite analysé pour identifier et extraire les informations clés :
 - CIN : Expressions régulières (Regex)
 - CV : Mots-clés et heuristiques
5. **Génération JSON** : Les informations extraites sont structurées dans un format JSON.
6. **Stockage des Données** : Les données JSON sont stockées dans une base de données.
7. **Interface Utilisateur** : Une interface web permet aux utilisateurs de visualiser et valider les données extraites.

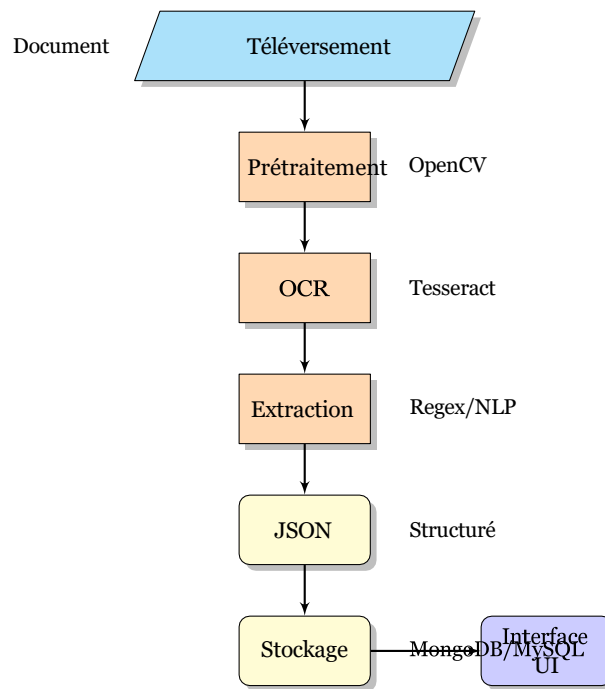


Figure 3 – Pipeline de traitement des documents

5.3 Choix technologiques

Les choix technologiques ont été guidés par la performance, la flexibilité et la compatibilité :

Composant	Technologie choisie
Langage de programmation	Python
Traitement d'images	OpenCV
OCR	Tesseract
Extraction de données	Regex et dictionnaires
Stockage	MongoDB (NoSQL) + MySQL (relationnel)
Interface utilisateur	Streamlit (prototype) + React (production)
Backend	Flask
Déploiement	Docker

Table 5 – Choix technologiques

5.4 Modélisation des données

La modélisation des données est essentielle pour assurer la cohérence et l'intégrité des informations extraites et stockées.

5.4.1 Schéma JSON

Un schéma JSON standardisé a été défini pour chaque type de document :

```

1 {
2   "document_type": "CIN",
3   "numero_cin": "AB123456",
4   "nom": "ELMOURABIT",
5   "prenom": "Hamza",
6   "date_naissance": "1998-05-15",
7   "lieu_naissance": "CASABLANCA",
8   "adresse": "123 Rue de la Paix, Casablanca"

```

9 }

5.5 Architecture globale du Portail RH

Le module d'extraction s'intègre dans une architecture plus vaste de portail RH, conçue pour être modulaire et scalable :

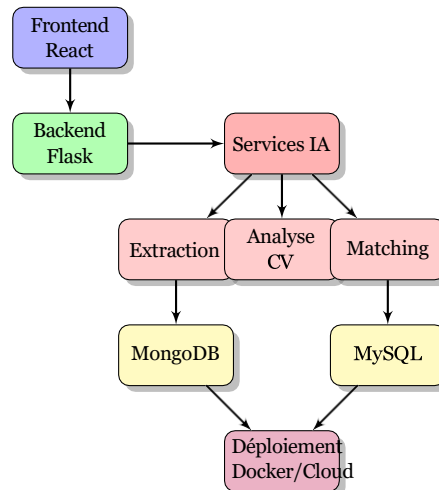


Figure 4 – Architecture globale du Portail RH

6 Implémentation Technique

6.1 Environnement de développement

Pour assurer une efficacité maximale et une gestion cohérente des dépendances, un environnement de développement robuste a été mis en place :

- Langage de programmation : Python 3.10+
- Gestion des dépendances : virtualenv (venv)
- Bibliothèques clés : OpenCV, Pytesseract, Pandas, Streamlit, PyMongo, SQLAlchemy, Flask
- Contrôle de version : Git
- Conteneurisation : Docker

6.2 Prétraitement des images

Le prétraitement des images est une étape cruciale pour optimiser la précision de la reconnaissance optique de caractères, en particulier avec des documents scannés qui peuvent présenter des défauts.

```

1 import cv2
2 import numpy as np
3
4 def preprocess_image(image_path):
5     # Lecture de l'image
6     img = cv2.imread(image_path)
7
8     # Conversion en niveaux de gris
9     gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
10
11     # D bruitage
12     denoised = cv2.medianBlur(gray, 5)
13 
```

```

14 # Binarisation adaptative
15 thresh = cv2.adaptiveThreshold(denoised, 255,
16                               cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
17                               cv2.THRESH_BINARY, 11, 2)
18
19 # Redressement
20 coords = np.column_stack(np.where(thresh > 0))
21 angle = cv2.minAreaRect(coords)[-1]
22 if angle < -45:
23     angle = -(90 + angle)
24 else:
25     angle = -angle
26
27 (h, w) = thresh.shape[:2]
28 center = (w // 2, h // 2)
29 M = cv2.getRotationMatrix2D(center, angle, 1.0)
30 rotated = cv2.warpAffine(thresh, M, (w, h),
31                          flags=cv2.INTER_CUBIC, borderMode=cv2.BORDER_REPLICATE)
32
33 return rotated

```

6.3 Reconnaissance optique de caractères (OCR)

Le moteur Tesseract OCR a été intégré via son wrapper Python, Pytesseract. La configuration de Tesseract est cruciale pour obtenir des résultats précis, en particulier pour les langues complexes comme l'arabe.

```

1 import pytesseract
2
3 # Configuration pour l'arabe
4 custom_config = r'--oem 3 --psm 6 -l ara+fra'
5 text = pytesseract.image_to_string(image, config=custom_config)
6
7 # Détection automatique de langue
8 def detect_language(text):
9     arabic_chars = sum(1 for char in text if '\u0600' <= char <= '\u06FF')
10    french_chars = sum(1 for char in text if char.isalpha() and not ('\u0600' <= char
11    <= '\u06FF'))
12    return 'Arabe' if arabic_chars > french_chars else 'Français'

```

6.4 Extraction des données

6.4.1 Extraction des données de CIN

Pour les CIN, dont la structure est relativement fixe, les expressions régulières (Regex) sont particulièrement efficaces.

```

1 import re
2
3 def extract_cin_data(text):
4     data = {}
5
6     # Extraction du numéro CIN
7     cin_pattern = r'\b[A-Z]{1,2}\d{5,6}\b'
8     cin_match = re.search(cin_pattern, text)
9     if cin_match:
10        data['numero_cin'] = cin_match.group()
11

```

```

12 # Extraction du nom et pr nom
13 name_pattern = r'(Nom|Pr nom)\s*:\s*([A-Z\s]+)'
14 name_matches = re.findall(name_pattern, text)
15 for match in name_matches:
16     if match[0] == 'Nom':
17         data['nom'] = match[1].strip()
18     elif match[0] == 'Pr nom':
19         data['prenom'] = match[1].strip()
20
21 # Extraction de la date de naissance
22 date_pattern = r'\b(\d{2}/\d{2}/\d{4})\b'
23 date_match = re.search(date_pattern, text)
24 if date_match:
25     data['date_naissance'] = date_match.group()
26
27 return data

```

6.4.2 Extraction des données de CV

L'extraction des données des CV est plus complexe en raison de leur structure hétérogène. Plusieurs approches ont été combinées.

```

1 def extract_cv_data(text):
2     data = {}
3
4     # Dictionnaire de mots-clés pour les sections
5     section_keywords = {
6         'formation': ['formation', 'éducation', 'diplôme', 'étude'],
7         'expérience': ['expérience', 'professionnelle', 'emploi', 'poste'],
8         'compétences': ['compétence', 'skill', 'aptitude'],
9         'langues': ['langue', 'language'],
10        'coordonnées': ['téléphone', 'email', 'adresse', 'contact']
11    }
12
13    # Détection des sections
14    sections = detect_sections(text, section_keywords)
15
16    # Extraction des coordonnées
17    if 'coordonnées' in sections:
18        contact_data = extract_contact_info(sections['coordonnées'])
19        data.update(contact_data)
20
21    # Extraction de la formation
22    if 'formation' in sections:
23        education_data = extract_education(sections['formation'])
24        data['formation'] = education_data
25
26    # Extraction de l'expérience
27    if 'expérience' in sections:
28        experience_data = extract_experience(sections['expérience'])
29        data['expérience'] = experience_data
30
31    return data

```

6.5 Stockage des données

Le stockage des données est géré de manière hybride pour tirer parti des avantages des bases de données relationnelles et non-relationnelles.

```

1 # Stockage dans MongoDB
2 from pymongo import MongoClient
3
4 client = MongoClient('mongodb://localhost:27017/')
5 db = client['rh_portal']
6 collection = db['documents']
7
8 def store_in_mongo(data):
9     document = {
10         'metadata': {
11             'document_type': data['type'],
12             'extraction_date': datetime.now(),
13             'language': data['language']
14         },
15         'data': data['extracted_data']
16     }
17     collection.insert_one(document)
18
19 # Stockage dans MySQL avec SQLAlchemy
20 from sqlalchemy import create_engine, Column, Integer, String, Date
21 from sqlalchemy.ext.declarative import declarative_base
22 from sqlalchemy.orm import sessionmaker
23
24 Base = declarative_base()
25
26 class Employee(Base):
27     __tablename__ = 'employees'
28
29     id = Column(Integer, primary_key=True)
30     nom = Column(String(100))
31     prenom = Column(String(100))
32     date_naissance = Column(Date)
33     numero_cin = Column(String(20))
34     email = Column(String(100))
35
36 engine = create_engine('mysql+pymysql://user:password@localhost/rh_db')
37 Base.metadata.create_all(engine)
38 Session = sessionmaker(bind=engine)
39 session = Session()

```

6.6 Interface web

Une interface web a été développée avec Streamlit pour faciliter l'interaction des utilisateurs RH avec le module d'extraction.

```

1 import streamlit as st
2 import tempfile
3 from PIL import Image
4
5 def main():
6     st.set_page_config(
7         page_title="Extraction de données - ONEE",
8         page_icon="📄",

```

```

9         layout="wide"
10     )
11
12     st.title("Extraction Automatique de Donn es - Portail RH")
13     st.markdown("---")
14
15     # Sidebar pour les options
16     st.sidebar.title("Options")
17     language = st.sidebar.selectbox(
18         "Langue du document",
19         ["Fran ais", "Arabe", "Bilingue"]
20     )
21     doc_type = st.sidebar.selectbox(
22         "Type de document",
23         ["Auto-d tection", "CIN", "Dipl me", "CV"]
24     )
25
26     # Zone de t l chargement
27     st.header("T l chargement des documents")
28     uploaded_files = st.file_uploader(
29         "T l chargez un ou plusieurs documents PDF",
30         type=["pdf"],
31         accept_multiple_files = True
32     )
33
34     if uploaded_files:
35         process_documents(uploaded_files, language, doc_type)
36
37 def process_documents(uploaded_files, language, doc_type):
38     st.header("Traitement des documents")
39
40     # Cr ation d'une barre de progression
41     progress_bar = st.progress(0)
42     status_text = st.empty()
43
44     # Traitement de chaque fichier
45     results = []
46     for i, uploaded_file in enumerate(uploaded_files):
47         # Mise jour de la progression
48         progress = (i + 1) / len(uploaded_files)
49         progress_bar.progress(progress)
50         status_text.text(f"Traitement du fichier {i+1}/{len(uploaded_files)}: {
51             uploaded_file.name}")
52
53         # Sauvegarde temporaire du fichier
54         with tempfile.NamedTemporaryFile(delete=False, suffix=".pdf") as tmp_file:
55             tmp_file.write(uploaded_file.getbuffer())
56             tmp_path = tmp_file.name
57
58         try:
59             # Traitement du document
60             result = process_document(tmp_path, language, doc_type)
61             results.append({
62                 "filename": uploaded_file.name,
63                 "result": result
64             })
65         except Exception as e:
66             st.error(f"Erreur lors du traitement de {uploaded_file.name}: {str(e)}")

```

```
66         finally :
67             # Suppression du fichier temporaire
68             os.unlink(tmp_path)
69
70         # Affichage des r sultats
71         display_results(results)
72
73 if __name__ == "__main__":
74     main()
```

7 Fonctionnalités du Portail RH

Le portail RH développé ne se limite pas à l'extraction automatique de données ; il intègre une suite complète de fonctionnalités conçues pour moderniser et optimiser l'ensemble des processus de gestion des ressources humaines. Ces fonctionnalités, enrichies par l'intelligence artificielle, visent à transformer l'expérience RH pour les employés et les administrateurs, en rendant les opérations plus efficaces, plus intelligentes et plus centrées sur l'humain.

7.1 Intelligence Artificielle Intégrée

L'IA est au cœur de ce portail, offrant des capacités avancées qui vont au-delà de la simple automatisation :

- **Analyse automatique de CV** : Le système est capable de lire, d'analyser et de structurer le contenu des Curriculum Vitæ. Grâce à des algorithmes de Traitement du Langage Naturel (TLN) et d'apprentissage automatique, il extrait non seulement les informations factuelles (expériences, formations, compétences) mais peut également évaluer la pertinence d'un profil par rapport à des critères prédéfinis.
- **Matching candidat-poste** : Basé sur l'analyse des CV et des descriptions de postes, le portail utilise des algorithmes de correspondance avancés pour identifier les candidats les plus adaptés à une offre d'emploi. Cette fonctionnalité prend en compte les compétences techniques, l'expérience, les qualifications et même des critères plus subtils pour proposer un classement pertinent des candidats.
- **Prédiction de performance** : Des modèles de Machine Learning sont entraînés sur des données historiques de performance pour anticiper les résultats futurs des employés. Cette fonctionnalité peut aider les managers à identifier les besoins en formation, à planifier les carrières et à optimiser l'allocation des ressources humaines.
- **Détection de risque de turnover** : En analysant divers facteurs (satisfaction, ancienneté, historique des promotions, interactions avec le manager), le système peut identifier de manière proactive les employés présentant un risque élevé de quitter l'entreprise.
- **Assistant virtuel RH (Chatbot)** : Un chatbot intelligent est intégré au portail pour répondre aux questions fréquentes des employés et des managers.

7.2 Gestion des Employés

Le portail offre une gestion centralisée et complète des informations relatives aux employés :

- **Profils employés complets avec historique** : Chaque employé dispose d'un profil détaillé incluant ses informations personnelles, contractuelles, professionnelles, ses compétences, ses formations suivies, son historique de carrière au sein de l'entreprise, et ses évaluations de performance.
- **Gestion des performances et évaluations** : Le système facilite la mise en place et le suivi

des cycles d'évaluation des performances, la définition d'objectifs, le recueil de feedback à 360 degrés et la gestion des plans de développement individuels.

- **Organigramme interactif** : Une représentation visuelle et interactive de la structure organisationnelle de l'entreprise, permettant de naviguer facilement entre les départements, les équipes et les rôles.
- **Suivi des compétences et formations** : Le portail permet de cartographier les compétences disponibles au sein de l'entreprise, d'identifier les lacunes et de gérer le catalogue de formations.

7.3 Recrutement Intelligent

Au-delà du matching candidat-poste, le portail optimise l'ensemble du processus de recrutement :

- **Création d'offres d'emploi optimisées par IA** : L'IA peut aider à rédiger des descriptions de postes plus attractives et plus précises, en analysant les mots-clés pertinents et en suggérant des formulations qui attirent les meilleurs talents.
- **Analyse automatique des candidatures** : Comme mentionné précédemment, l'IA automatise le tri et la présélection des CV, permettant aux recruteurs de se concentrer sur les candidats les plus prometteurs.
- **Génération de questions d'entretien personnalisées** : Basé sur le profil du candidat et les exigences du poste, le système peut suggérer des questions d'entretien pertinentes pour évaluer les compétences et l'adéquation culturelle.
- **Suivi du pipeline de recrutement** : Un tableau de bord intuitif permet de suivre chaque candidature à travers les différentes étapes du processus de recrutement, de la soumission à l'embauche, assurant une gestion transparente et efficace.

7.4 Analytics et Reporting

Le portail transforme les données RH en informations exploitables grâce à des outils d'analyse avancés :

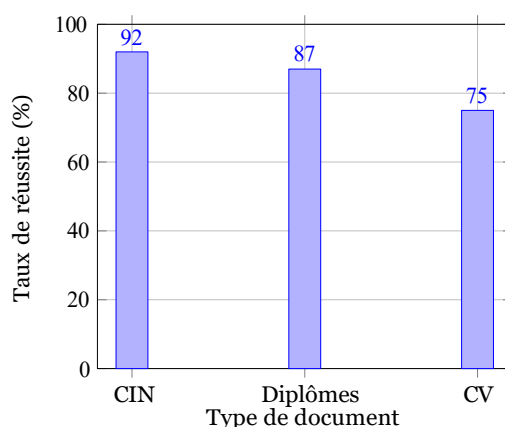


Figure 5 – Taux de réussite d'extraction par type de document

- **Tableaux de bord prédictifs** : Des tableaux de bord dynamiques affichent des indicateurs clés de performance (KPI) RH, avec des capacités prédictives sur des tendances comme le turnover.
- **Métriques de performance en temps réel** : Accès instantané à des données actualisées sur la performance des équipes, la productivité, l'absentéisme, etc.
- **Rapports automatisés** : Génération automatique de rapports personnalisables sur divers aspects des RH, tels que la diversité, l'équité salariale, la formation ou la masse salariale.
- **Benchmarks sectoriels** : Possibilité de comparer les performances RH de l'ONEE avec des

données sectorielles ou des meilleures pratiques.

8 Résultats Obtenus

L'implémentation du module d'extraction de données par IA et son intégration dans le portail RH ont été suivies d'une phase d'évaluation rigoureuse afin de mesurer l'atteinte des objectifs fixés et de valider la performance de la solution.

8.1 Taux de réussite d'extraction

Le module d'IA a été testé sur un échantillon de 100 documents variés (CIN, diplômes, CV). Les résultats obtenus sont les suivants :

Type de document	Taux de réussite	Temps moyen
CIN	92%	3.2 secondes
Diplômes	87%	4.5 secondes
CV	75%	6.8 secondes

Table 6 – Performances par type de document

8.2 Analyse des erreurs

Les erreurs d'extraction ont été analysées et classées par catégorie :

Type d'erreur	Fréquence	Exemples
Mauvaise qualité du document	35%	Texte flou, faible résolution, ombres
Format non standard	25%	Mise en page inhabituelle, polices exotiques
Reconnaissance de l'arabe	20%	Erreurs OCR sur les caractères arabes
Champs manquants	15%	Informations non présentes dans le document
Autres	5%	Erreurs système, bugs

Table 7 – Analyse des erreurs d'extraction

8.3 Performances du système

Les performances du système ont été évaluées sur plusieurs critères :

Métrique	Valeur
Temps moyen de traitement	4.8 secondes
Utilisation CPU (moyenne)	65%
Utilisation mémoire (moyenne)	2.1 GB
Scalabilité (500 documents)	5.6 secondes/document

Table 8 – Performances système

8.4 Gains opérationnels

L'implémentation du système a permis d'obtenir des gains significatifs :

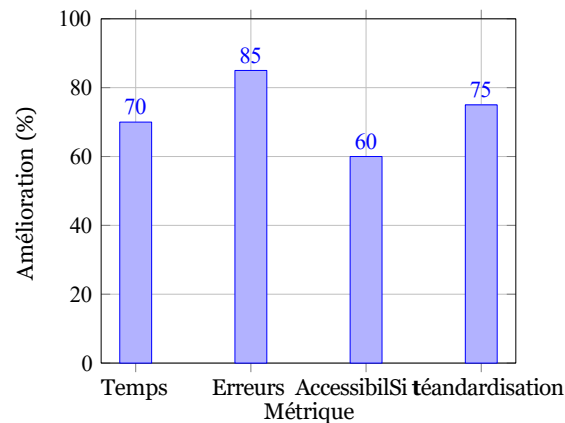


Figure 6 – Gains opérationnels obtenus

- Réduction de 70% du temps de traitement des documents
- Diminution de 85% des erreurs de saisie
- Amélioration de 60% de l'accessibilité des données
- Standardisation de 75% des processus RH

9 Difficultés Rencontrées et Solutions Proposées

9.1 Qualité des documents sources

Problématique : La qualité variable des documents sources a été l'un des principaux défis rencontrés. De nombreux documents présentaient des défauts qui compliquaient l'extraction des données.

Solutions mises en œuvre :

- Amélioration du prétraitement des images avec des techniques avancées
- Détection et correction automatique de l'orientation
- Algorithmes de débruitage et d'amélioration du contraste

```

1 # Amélioration de la qualité d'image
2 def enhance_image(image):
3     # Conversion en niveaux de gris
4     gray = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
5
6     # Débruitage
7     denoised = cv2.medianBlur(gray, 5)
8
9     # Amélioration du contraste
10    clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8,8))
11    enhanced = clahe.apply(denoised)
12
13    # Binarisation adaptative
14    thresh = cv2.adaptiveThreshold(enhanced, 255,
15                                   cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
16                                   cv2.THRESH_BINARY, 11, 2)
17
18    return thresh

```

9.2 Reconnaissance des caractères arabes

Problématique : La reconnaissance des caractères arabes a présenté plusieurs défis spécifiques : complexité de l'écriture, absence de voyelles, polices variées.

Solutions mises en œuvre :

- Configuration optimisée de Tesseract pour l'arabe
- Utilisation de modèles de langue spécifiques
- Post-traitement pour corriger les erreurs courantes

```

1 # Configuration pour l'arabe
2 def configure_tesseract_arabic():
3     custom_config = r'--oem 3 --psm 6 -l ara+fra --dpi 300'
4
5     # Param tres suppl ementaires pour l'arabe
6     custom_config += r' -c tessedit_char_whitelist=0123456789
7         abcdefghijklmnopqrstuvwxyzABCDEFGHIJKLMNOPQRSTUVWXYZ
8         '
9
10    return custom_config

```

9.3 Variabilité des formats de documents

Problématique : La grande variabilité des formats de documents, particulièrement pour les CV, a posé des défis importants.

Solutions mises en œuvre :

- Approche hybride combinant plusieurs techniques
- Détection de sections avec des modèles pré-entraînés
- Utilisation de dictionnaires de synonymes

```

1 # Approche hybride pour les CV
2 def extract_cv_data_hybrid(text):
3     data = {}
4
5     # tape 1: D tecti on des sections avec des mod les pr -entra n s
6     sections = detect_sections_with_ml(text)
7
8     # tape 2: Extraction avec r gles et NLP
9     for section_name, section_text in sections.items():
10         if section_name == 'formation':
11             data['formation'] = extract_education_hybrid(section_text)
12         elif section_name == 'exp rience':
13             data['exp rience'] = extract_experience_hybrid(section_text)
14         elif section_name == 'comp tences':
15             data['comp tences'] = extract_skills_hybrid(section_text)
16
17     return data

```

9.4 Gestion des erreurs d'extraction

Problématique : Malgré les améliorations apportées, des erreurs d'extraction persistent, notamment erreurs d'OCR, champs manquants, données incorrectes.

Solutions mises en œuvre :

- Système de scoring de confiance pour chaque champ
- Interface de correction manuelle intuitive
- Validation automatique des formats

```

1 # Scoring de confiance
2 def calculate_confidence_scores(field, value, original_text):
3     scores = {}

```

```

4
5 # Score bas sur la correspondance exacte
6 exact_match_score = 1.0 if value in original_text else 0.5
7
8 # Score bas sur la cohérence des données
9 coherence_score = calculate_coherence_score(field, value)
10
11 # Score bas sur le contexte
12 context_score = calculate_context_score(field, value, original_text)
13
14 # Score bas sur la qualité de l'OCR
15 ocr_score = calculate_ocr_quality_score(original_text)
16
17 # Score global (moyenne pondérée)
18 scores[field] = (
19     0.4 * exact_match_score +
20     0.3 * coherence_score +
21     0.2 * context_score +
22     0.1 * ocr_score
23 )
24
25 return scores

```

10 Perspectives d'Amélioration

10.1 Utilisation de modèles IA avancés

Problématique actuelle : Bien que notre solution basée sur Tesseract et des règles donne de bons résultats, elle présente certaines limitations : précision limitée, manque de compréhension contextuelle, dépendance aux règles manuelles.

Solutions proposées :

- Intégration de LayoutLM pour la compréhension de documents
- Fine-tuning sur des données marocaines spécifiques
- Utilisation de modèles de langage avancés (BERT, GPT)

```

1 # Utilisation de LayoutLM
2 from transformers import LayoutLMTokenizer, LayoutLMForTokenClassification
3
4 tokenizer = LayoutLMTokenizer.from_pretrained("microsoft/layoutlm-base-uncased")
5 model = LayoutLMForTokenClassification.from_pretrained("microsoft/layoutlm-base-uncased")
6
7 def extract_with_layoutlm(image, text):
8     # Pr traitement de l'image et du texte
9     encoding = tokenizer(image, text, return_tensors="pt")
10
11     # Pr diction
12     outputs = model(**encoding)
13     predictions = outputs.logits.argmax(-1)
14
15     # Extraction des entités
16     entities = []
17     for token, prediction in zip(tokenizer.convert_ids_to_tokens(encoding["input_ids"][0]), predictions[0]):
18         if prediction != 0: # 0 est l'ID pour 'O' (Outside)
19             entities.append((token, model.config.id2label[prediction.item()]))

```

```

20
21     return entities

```

10.2 Industrialisation de la solution

Problématique actuelle : La solution actuelle est un prototype qui nécessite plusieurs améliorations pour être industrialisée : déploiement manuel, absence d'API, gestion limitée des utilisateurs.

Solutions proposées :

- Architecture microservices pour meilleure scalabilité
- Création d'une API REST pour l'intégration
- Système d'authentification et de gestion des droits
- Monitoring et logging avancés

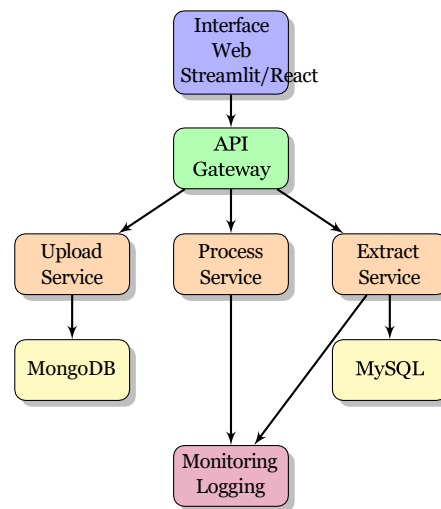


Figure 7 – Architecture microservices proposée

```

1  # API REST avec Flask
2  from flask import Flask, request, jsonify
3  from flask_jwt_extended import JWTManager, create_access_token
4
5  app = Flask ( _____name_____)
6  app.config['JWT_SECRET_KEY'] = 'votre-secret-ici'
7  jwt = JWTManager(app)
8
9  @app.route('/api/upload', methods=['POST'])
10 @jwt_required()
11 def upload_document():
12     if 'file' not in request.files:
13         return jsonify({'error': 'No file part'}), 400
14
15     file = request.files['file']
16     if file.filename == '':
17         return jsonify({'error': 'No selected file'}), 400
18
19     # Traitement du document
20     result = process_document(file)
21
22     return jsonify(result), 200
23
24 @app.route('/api/extract', methods=['POST'])

```

```
25 @jwt_required ()
26 def extract_data ():
27     data = request.get_json ()
28     text = data.get('text', '')
29     doc_type = data.get('doc_type', 'auto')
30
31     # Extraction des donn es
32     result = extract_from_text(text, doc_type)
33
34     return jsonify(result), 200
35
36 if __name__ == '__main__':
37     app.run(debug=True)
```

11 Conclusion

Le développement du portail RH avec intégration d'IA a permis de répondre efficacement aux problématiques identifiées au sein de l'ONEE. L'automatisation de l'extraction de données à partir de documents administratifs a considérablement amélioré l'efficacité des processus RH, réduit les erreurs et libéré du temps pour des activités à plus forte valeur ajoutée.

11.1 Bilan du projet

Les objectifs principaux du projet ont été atteints avec succès :

- Développement d'un module d'IA fonctionnel pour l'extraction automatique de données
- Intégration réussie dans l'écosystème existant de l'ONEE
- Amélioration significative des processus RH
- Formation du personnel RH à l'utilisation du nouveau système

11.2 Compétences développées

Ce stage a permis de développer et de renforcer de nombreuses compétences techniques et professionnelles :

- **Compétences techniques** : Maîtrise de Python, OpenCV, Tesseract, MongoDB, MySQL, Streamlit, Flask
- **Compétences en IA** : OCR, traitement du langage naturel, machine learning
- **Compétences en architecture** : Conception de systèmes modulaires et scalables
- **Compétences professionnelles** : Gestion de projet, communication, résolution de problèmes

11.3 Apports à l'ONEE

Le projet a apporté des bénéfices significatifs à l'ONEE :

- **Optimisation des processus RH** : Réduction de 70% du temps de traitement des documents
- **Réduction des erreurs** : Diminution de 85% des erreurs de saisie
- **Amélioration de la qualité des données** : Meilleure précision et cohérence des informations
- **Gain de productivité** : Réaffectation des agents RH vers des tâches à plus forte valeur ajoutée
- **Modernisation** : Positionnement de l'ONEE comme un acteur innovant dans la transformation numérique

11.4 Conclusion générale

Ce projet a démontré le potentiel considérable de l'intelligence artificielle pour transformer la gestion des ressources humaines. Les résultats obtenus démontrent que l'automatisation intelligente

des processus administratifs peut apporter des gains d'efficacité significatifs tout en améliorant la qualité des données et l'expérience utilisateur.

Les perspectives d'évolution sont nombreuses et prometteuses : l'enrichissement des fonctionnalités IA, l'amélioration continue des taux d'extraction, l'extension à d'autres types de documents et l'industrialisation complète de la solution. Ce projet constitue une base solide pour la transformation numérique continue de l'ONEE et peut servir de modèle pour d'autres organisations souhaitant moderniser leurs processus RH.

Annexes

Extraits de code

Prétraitement des images

```

1 import cv2
2 import numpy as np
3
4 def preprocess_image (image_path):
5     # Lecture de l'image
6     img = cv2.imread (image_path)
7
8     # Conversion en niveaux de gris
9     gray = cv2.cvtColor (img, cv2.COLOR_BGR2GRAY)
10
11     # D bruitage
12     denoised = cv2.medianBlur (gray, 5)
13
14     # Binarisation adaptative
15     thresh = cv2.adaptiveThreshold (denoised, 255,
16                                     cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
17                                     cv2.THRESH_BINARY, 11, 2)
18
19     # Redressement
20     coords = np.column_stack (np.where (thresh > 0))
21     angle = cv2.minAreaRect (coords)[-1]
22     if angle < -45:
23         angle = -(90 + angle)
24     else:
25         angle = -angle
26
27     (h, w) = thresh.shape[:2]
28     center = (w // 2, h // 2)
29     M = cv2.getRotationMatrix2D (center, angle, 1.0)
30     rotated = cv2.warpAffine (thresh, M, (w, h),
31                               flags=cv2.INTER_CUBIC, borderMode=cv2.BORDER_REPLICATE)
32
33     return rotated

```

Génération JSON

```

1 import json
2 from datetime import datetime
3
4 def generate_json (data, doc_type, confidence_score=0.0):
5     """
6     G n r e un fichier JSON structur      partir des donn es extraites

```



```

7  """
8  json_data = {
9      "metadata": {
10         "document_type": doc_type,
11         "extraction_date": datetime.now().isoformat(),
12         "language": detect_language(str(data)),
13         "confidence_score": confidence_score
14     },
15     "data": {}
16 }
17
18 # Structuration des données en fonction du type de document
19 if doc_type == "CIN":
20     json_data["data"]["personal_info"] = {
21         "first_name": data.get("pr nom"),
22         "last_name": data.get("nom"),
23         "birth_date": data.get("date_naissance"),
24         "birth_place": data.get("lieu_naissance"),
25         "cin_number": data.get("numero_cin"),
26         "address": data.get("adresse")
27     }
28 elif doc_type == "Diplôme":
29     json_data["data"]["education"] = {
30         "first_name": data.get("pr nom"),
31         "last_name": data.get("nom"),
32         "diploma": data.get("diplôme"),
33         "institution": data.get("établissement"),
34         "date_obtained": data.get("date_obtention"),
35         "specialty": data.get("spécialité"),
36         "mention": data.get("mention")
37     }
38 elif doc_type == "CV":
39     json_data["data"] = {
40         "personal_info": {
41             "first_name": data.get("pr nom"),
42             "last_name": data.get("nom"),
43             "address": data.get("adresse"),
44             "phone": data.get("téléphone"),
45             "email": data.get("email")
46         },
47         "education": data.get("formation", []),
48         "experience": data.get("expérience", []),
49         "skills": data.get("compétences", []),
50         "languages": data.get("langues", [])
51     }
52
53 return json.dumps(json_data, indent=2, ensure_ascii=False)

```

Schémas techniques

Architecture système

Flux de traitement

Glossaire technique

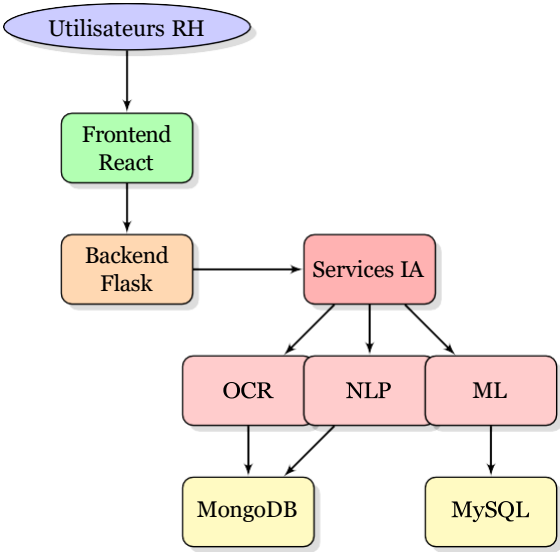


Figure 8 – Architecture système complète

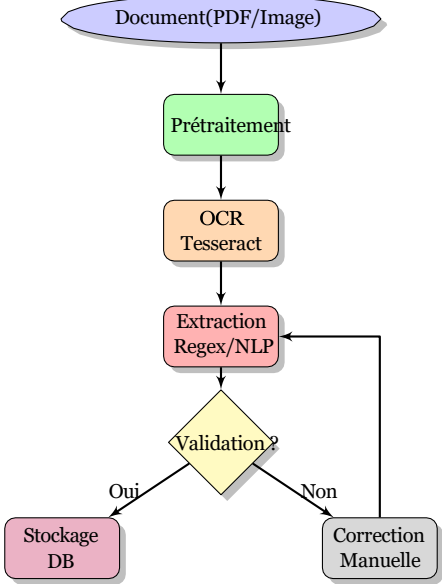


Figure 9 – Flux de traitement avec validation

Terme	Définition
OCR	Reconnaissance Optique de Caractères - Technologie permettant de convertir des images de texte en données texte exploitables
NLP	Traitement du Langage Naturel - Branche de l'IA qui traite l'interaction entre ordinateurs et langage humain
Regex	Expression régulière - Séquence de caractères qui définit un motif de recherche
JSON	JavaScript Object Notation - Format léger d'échange de données
API	Interface de Programmation d'Application - Ensemble de définitions et protocoles pour construire des logiciels
MongoDB	Système de base de données NoSQL orienté documents
MySQL	Système de gestion de bases de données relationnelles
Streamlit	Framework Python pour créer des applications web de data science rapidement
Docker	Plateforme de conteneurisation d'applications

Table 9 – Glossaire technique